Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления»

Кафедра ИУ5 «Системы обработки информации и управления»

Отчет по лабораторной работе №2

по дисциплине «Методы машинного обучения»

по теме «Обработка признаков (часть 1)»

Выполнил:
студент группы № ИУ5-24М
Попов М.А.
подпись, дата

Проверил:

подпись, дата

2024 г.

Задание:

1. Выбрать набор данных (датасет), содержащий категориальные и числовые признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.) Просьба не использовать датасет, на котором данная задача решалась в лекции.

2. Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:

• устранение пропусков в данных;

• кодирование категориальных признаков;

• нормализация числовых признаков.

, , Обработка пропусков в данных кодирование категориальных признаков масштабирование данных .

Загрузка и первичный анализ данных

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import sklearn.impute
import sklearn.preprocessing
%matplotlib inline
sns.set(style="ticks")

data=pd.read_csv("sample_data/
Video_Games_Sales_as_at_22_Dec_2016.csv")

from IPython.display import set_matplotlib_formats
set_matplotlib_formats("retina")

# Первые 5 строк датасета
data.head()
```

```
 Name Platform Year_of_Release Genre  Publisher \
0 Wii Sports Wii 2006.0 Sports  Nintendo
1 Super Mario Bros. NES 1985.0 Platform  Nintendo
2 Mario Kart Wii Wii 2008.0 Racing  Nintendo
3 Wii Sports Resort Wii 2009.0 Sports  Nintendo
4 Pokemon Red/Pokemon Blue GB 1996.0 Role-Playing  Nintendo

 NA_Sales EU_Sales JP_Sales Other_Sales Global_Sales  Critic_Score \
0 41.36 28.96 3.77 8.45 82.53  76.0
1 29.08 3.58 6.81 0.77 40.24  NaN
2 15.68 12.76 3.79 3.29 35.52  82.0
3 15.61 10.93 3.28 2.95 32.77  80.0
4 11.27 8.89 10.22 1.00 31.37  NaN

 Critic_Count User_Score User_Count Developer Rating
0 51.0 8 322.0 Nintendo E  1 NaN NaN NaN NaN NaN  2 73.0 8.3 709.0
Nintendo E  3 73.0 8 192.0 Nintendo E  4 NaN NaN NaN NaN NaN
```

```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count)) Всего строк:
```

```
16719
```

```
# типы колонок
data.dtypes
```

```
Name object
Platform object
Year_of_Release float64
Genre object
Publisher object
NA_Sales float64
EU_Sales float64
JP_Sales float64
Other_Sales float64
Global_Sales float64
Critic_Score float64
Critic_Count float64
User_Score object
User_Count float64
Developer object
Rating object
dtype: object
```

```
# размер набора данных
data.shape
```

```
(16719, 16)
```

Обработка пропусков в данных

```
# проверим есть ли пропущенные значения
data.isnull().sum()
```

```
Name 2
Platform 0
Year_of_Release 269
Genre 2
Publisher 54
NA_Sales 0
EU_Sales 0
JP_Sales 0
Other_Sales 0
Global_Sales 0
Critic_Score 8582
Critic_Count 8582
User_Score 6704
User_Count 9129
Developer 6623
Rating 6769
dtype: int64
```

```
# Удаление колонок, содержащих пустые значения
data_new_1 = data.dropna(axis=1, how='any')
```

```
(data.shape, data_new_1.shape)
```

```
((16719, 16), (16719, 6))
```

```
data_new_1.columns
```

```
Index(['Platform', 'NA_Sales', 'EU_Sales', 'JP_Sales', 'Other_Sales',  'Global_Sales'],
 dtype='object')
```

```
# Удаление строк, содержащих пустые значения
data_new_2 = data.dropna(axis=0, how='any')
 (data.shape, data_new_2.shape)
```

```
((16719, 16), (6825, 16))
```

```
# Найдем пропуски в данных в процентном соотношении
for col in data.columns:
 pct_missing = np.mean(data[col].isnull())
 print('{} - {}%'.format(col, round(pct_missing*100)))
```

```
Name - 0%
Platform - 0%
Year_of_Release - 2%
Genre - 0%
Publisher - 0%
NA_Sales - 0%
EU_Sales - 0%
JP_Sales - 0%
Other_Sales - 0%
Global_Sales - 0%
Critic_Score - 51%
Critic_Count - 51%
User_Score - 40%
User_Count - 55%
Developer - 40%
Rating - 40%
```

```
data[data.columns].isnull()
 Name Platform Year_of_Release Genre Publisher NA_Sales  EU_Sales \
0 False False False False False False  False
1 False False False False False False  False
2 False False False False False False  False
3 False False False False False False  False
4 False False False False False False  False
 ... ... ... ... ... ... ...  ...
16714 False False False False False False  False
16715 False False False False False False  False
16716 False False False False False False  False
16717 False False False False False False  False
16718 False False False False False False  False

 JP_Sales Other_Sales Global_Sales Critic_Score Critic_Count \
0 False False False False False 1 False False False True True 2 False False False False

False 3 False False False False False 4 False False False True True ... ... ... ... ... ... 16714
```

False False False True True 16715 False False False True True 16716 False False False True

True 16717 False False False True True 16718 False False False True True

```
 User_Score User_Count Developer Rating
0 False False False False
1 True True True True
2 False False False False
3 False False False False
4 True True True True
 ... ... ... ... ...
16714 True True True True
16715 True True True True
16716 True True True True
16717 True True True True
16718 True True True True

[16719 rows x 16 columns]
```

```
# Поработаем с заполнение пропусков в колонке "Year of release" colors =
['#FFF0F5', '#008B8B']
sns.heatmap(data[data.columns].isnull(),
cmap=sns.color_palette(colors))
```

<AxesSubplot:>

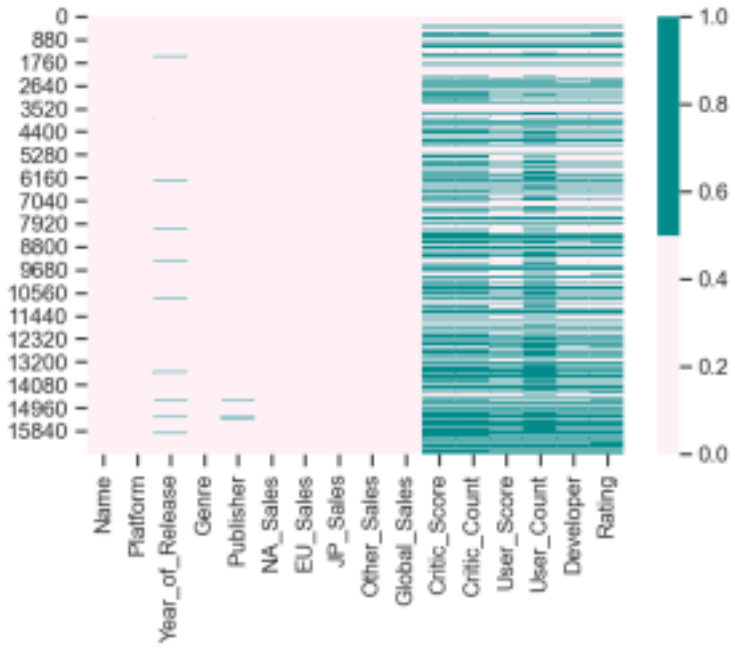


```
# Заполним пропуски в колонке нулями
sns.distplot(data['Year_of_Release'].fillna(0))
```

C:\Users\User\anaconda3\lib\site-packages\seaborn\
distributions.py:2551: FutureWarning: `distplot` is a deprecated function and will be removed in a future version. Please adapt your code to use either `displot` (a figure-level function with similar
flexibility) or `histplot` (an axes-level function for histograms). warnings.warn(msg, FutureWarning)

<AxesSubplot:xlabel='Year_of_Release', ylabel='Density'>

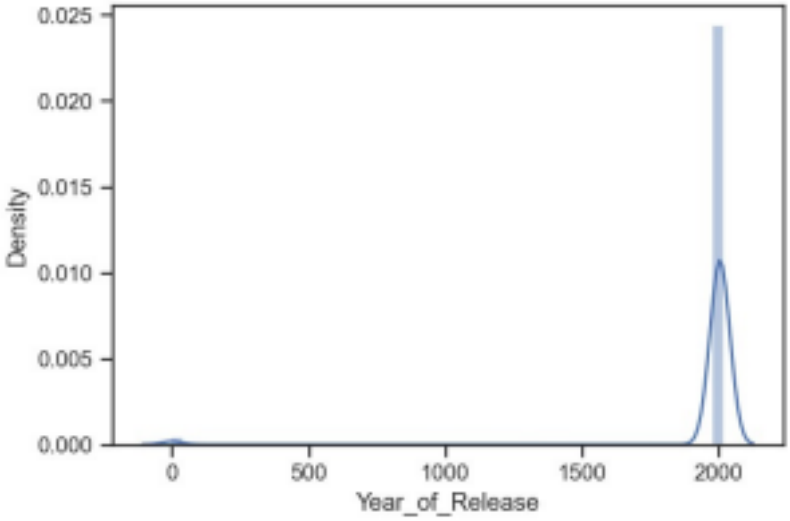


```
# Получаем совершенно не то, что нам нужно
# С помощью класса SimpleImputer можно проводить импьютацию различными показателями центра распределения
# Применим заполнение средними значениями
mean=sklearn.impute.SimpleImputer(strategy="mean") # Среднее значение
mean_rate=mean.fit_transform(data[['Year_of_Release']]) sns.distplot(mean_rate)
```

```
C:\Users\User\anaconda3\lib\site-packages\seaborn\
distributions.py:2551: FutureWarning: `distplot` is a deprecated  function and will be removed in a future version. Please adapt your  code to use either `displot` (a figure-level function with similar  flexibility) or `histplot` (an axes-level function for histograms).
warnings.warn(msg, FutureWarning)
```

```
<AxesSubplot:ylabel='Density'>
```

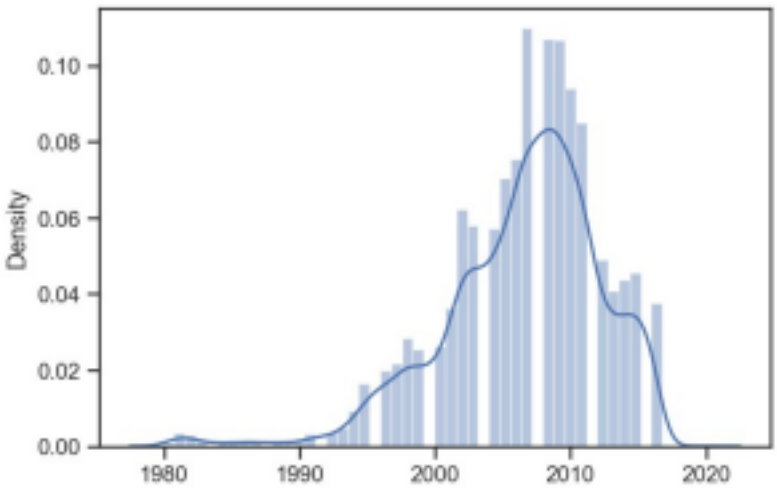


```
med=sklearn.impute.SimpleImputer(strategy="median") # Половина  элементов больше медианы, половина меньше
med_rate=med.fit_transform(data[['Year_of_Release']])
sns.distplot(med_rate)
```

```
C:\Users\User\anaconda3\lib\site-packages\seaborn\
distributions.py:2551: FutureWarning: `distplot` is a deprecated  function and will be removed in a future version. Please adapt your  code to use either `displot` (a figure-level function with similar  flexibility) or `histplot` (an axes-level function for histograms).
warnings.warn(msg, FutureWarning)
```

```
<AxesSubplot:ylabel='Density'>
```

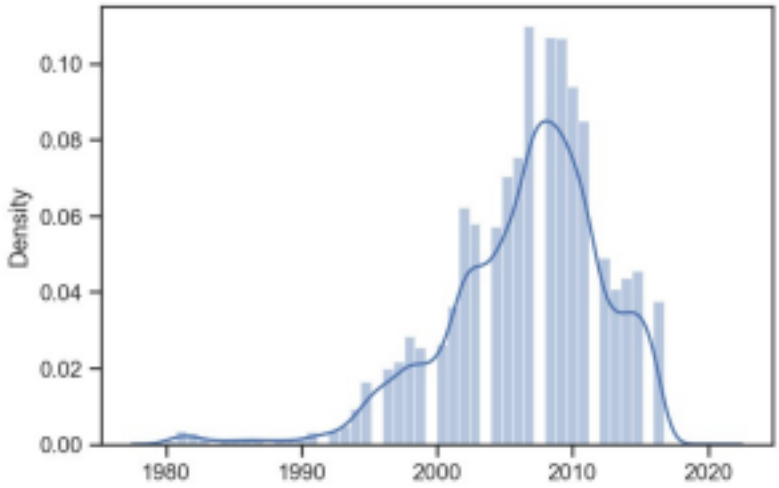


```
freq=sklearn.impute.SimpleImputer(strategy="most_frequent")
freq_rate=freq.fit_transform(data[['Year_of_Release']]) sns.distplot(freq_rate)
```

```
C:\Users\User\anaconda3\lib\site-packages\seaborn\
distributions.py:2551: FutureWarning: `distplot` is a deprecated
function and will be removed in a future version. Please adapt your  code to use either
`displot` (a figure-level function with similar  flexibility) or `histplot` (an axes-level function for
histograms).  warnings.warn(msg, FutureWarning)
```

```
<AxesSubplot:ylabel='Density'>
```

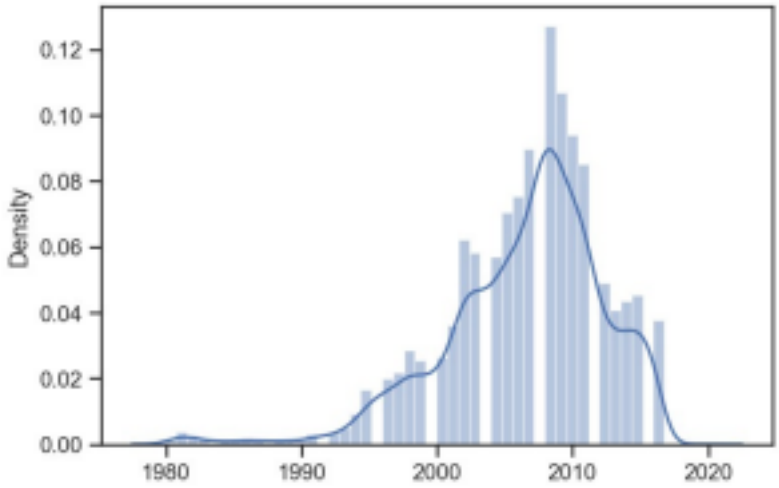


```
# Остановим выбор на средних значениях
data['Year_of_Release'] = mean_rate
```

Обработка пропусков в категориальных данных

```
# Выберем категориальные колонки с пропущенными значениями # Цикл
по колонкам датасета
 cat_cols = []
for col in data.columns:
 # Количество пустых значений
 temp_null_count = data[data[col].isnull()].shape[0]  dt =
str(data[col].dtype)
 if temp_null_count>0 and (dt=='object'):
 cat_cols.append(col)
 temp_perc = round((temp_null_count / total_count) * 100.0, 2)  print('Колонка {}. Тип данных
{}. Количество пустых значений  {}, {}%.'.format(col, dt, temp_null_count, temp_perc))
```

Колонка Name. Тип данных object. Количество пустых значений 2, 0.01%. Колонка Genre. Тип данных object. Количество пустых значений 2, 0.01%. Колонка Publisher. Тип данных object. Количество пустых значений 54, 0.32%.
Колонка User_Score. Тип данных object. Количество пустых значений 6704, 40.1%.
Колонка Developer. Тип данных object. Количество пустых значений 6623, 39.61%.
Колонка Rating. Тип данных object. Количество пустых значений 6769, 40.49%.

```
cat_temp_data = data[['Genre']]
cat_temp_data.head()
```

```
 Genre
0 Sports
1 Platform
2 Racing
3 Sports
4 Role-Playing
```

```
cat_temp_data['Genre'].unique()
```

```
array(['Sports', 'Platform', 'Racing', 'Role-Playing', 'Puzzle',  'Misc',
 'Shooter', 'Simulation', 'Action', 'Fighting', 'Adventure',  'Strategy', nan], dtype=object)
```

```
cat_temp_data[cat_temp_data['Genre'].isnull()]
```

```
 Genre
659 NaN
14246 NaN
```

```
# Импьютация наиболее частыми значениями
imp2 = sklearn.impute.SimpleImputer(missing_values=np.nan,
strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
```

```
array([['Sports'],
 ['Platform'],
 ['Racing'],
 ...,
 ['Adventure'],
 ['Platform'],
 ['Simulation']], dtype=object)
```

```
# Пустые значения отсутствуют
np.unique(data_imp2)
```

```
array(['Action', 'Adventure', 'Fighting', 'Misc', 'Platform',  'Puzzle',
 'Racing', 'Role-Playing', 'Shooter', 'Simulation', 'Sports',  'Strategy'], dtype=object)
```

```
# Импьютация константой
imp3 = sklearn.impute.SimpleImputer(missing_values=np.nan,
strategy='constant', fill_value='NA')
data_imp3 = imp3.fit_transform(cat_temp_data)
data_imp3
```

```
array([['Sports'],
 ['Platform'],
 ['Racing'],
 ...,
```

```
['Adventure'],
['Platform'],
['Simulation']], dtype=object)
```

```
np.unique(data_imp3)
```

```
array(['Action', 'Adventure', 'Fighting', 'Misc', 'NA', 'Platform', 'Puzzle', 'Racing',
'Role-Playing', 'Shooter', 'Simulation', 'Sports', 'Strategy'], dtype=object)
```

```
data_imp3[data_imp3=='NA'].size
```

```
2
```

```
data['Genre'] = data_imp2
```

```
data['Genre'].unique()
```

```
array(['Sports', 'Platform', 'Racing', 'Role-Playing', 'Puzzle', 'Misc',
'Shooter', 'Simulation', 'Action', 'Fighting', 'Adventure', 'Strategy'], dtype=object)
```

Кодирование категориальных признаков

```
types=data["Genre"]
types.value_counts()
```

```
Action 3372
Sports 2348
Misc 1750
Role-Playing 1500
Shooter 1323
Adventure 1303
Racing 1249
Platform 888
Simulation 874
Fighting 849
Strategy 683
Puzzle 580
Name: Genre, dtype: int64
```

Кодирование категорий целочисленными значениями - label encoding

```
le=sklearn.preprocessing.LabelEncoder()
type_le=le.fit_transform(types)
print(np.unique(type_le))
le.inverse_transform(np.unique(type_le))
[ 0 1 2 3 4 5 6 7 8 9 10 11]
```

```
array(['Action', 'Adventure', 'Fighting', 'Misc', 'Platform', 'Puzzle',
'Racing', 'Role-Playing', 'Shooter', 'Simulation', 'Sports', 'Strategy'], dtype=object)
```

Pandas get_dummies - one-hot быстрый вариант кодирования

```
type_s=pd.get_dummies(types)
type_s.head(25)
```

```
Action Adventure Fighting Misc Platform Puzzle Racing Role Playing \
0 0 0 0 0 0 0 0 0
1 0 0 0 0 1 0 0 0
```

2 0 0 0 0 0 0 1 0
3 0 0 0 0 0 0 0 0
4 0 0 0 0 0 0 0 1
5 0 0 0 0 0 1 0 0
6 0 0 0 0 1 0 0 0
7 0 0 0 1 0 0 0 0
8 0 0 0 0 1 0 0 0
9 0 0 0 0 0 0 0 0
10 0 0 0 0 0 0 0 0
11 0 0 0 0 0 0 1 0
12 0 0 0 0 0 0 0 1
13 0 0 0 0 0 0 0 0
14 0 0 0 1 0 0 0 0
15 0 0 0 0 0 0 0 0
16 1 0 0 0 0 0 0 0
17 1 0 0 0 0 0 0 0
18 0 0 0 0 1 0 0
0
19 0 0 0 1 0 0 0 0
20 0 0 0 0 0 0 0 1
21 0 0 0 0 1 0 0 0
22 0 0 0 0 1 0 0 0
23 1 0 0 0 0 0 0 0
24 1 0 0 0 0 0 0 0

Shooter Simulation Sports Strategy
0 0 0 1 0
1 0 0 0 0
2 0 0 0 0
3 0 0 1 0
4 0 0 0 0
5 0 0 0 0
6 0 0 0 0
7 0 0 0 0
8 0 0 0 0
9 1 0 0 0
10 0 1 0 0
11 0 0 0 0
12 0 0 0 0
13 0 0 1 0
14 0 0 0 0
15 0 0 1 0
16 0 0 0 0
17 0 0 0 0
18 0 0 0 0
19 0 0 0 0
20 0 0 0 0
21 0 0 0 0
22 0 0 0 0
23 0 0 0 0
24 0 0 0 0

Переходим к масштабированию данных .

Масштабирование предполагает изменение диапазона измерения величины а

нормализация изменение распределения этой величины , - .

Если признаки лежат в различных диапазонах то необходимо их , нормализовать Как правило применяют два следующих подхода . , :

MinMax масштабирование

```
from sklearn.preprocessing import MinMaxScaler, StandardScaler

sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['Year_of_Release']])

plt.hist(data['Year_of_Release'], 80)
plt.show()
```

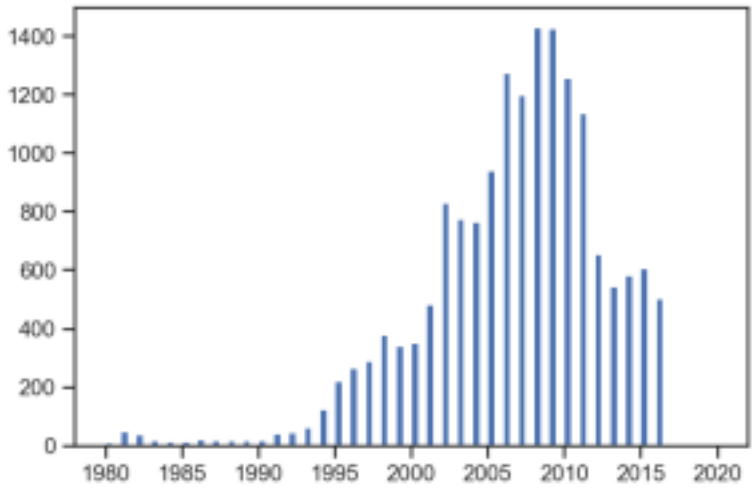


```
plt.hist(sc1_data, 80)
plt.show()
```

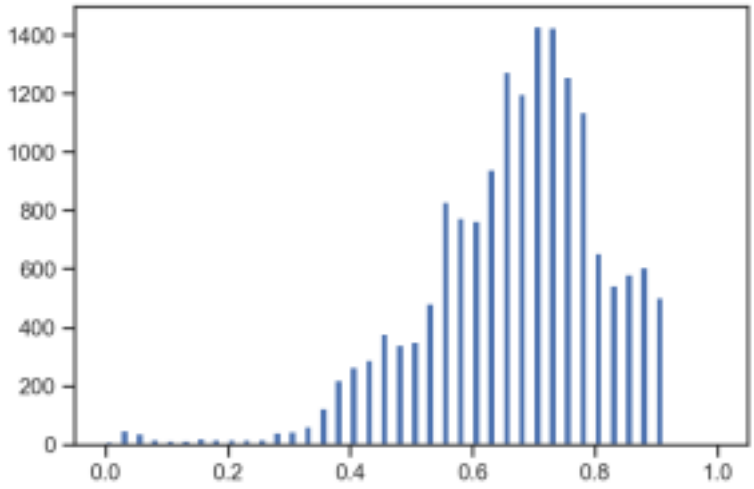

Масштабирование данных на основе Z-оценки - StandardScaler

```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['Year_of_Release']])

plt.hist(sc2_data, 50)
plt.show()
```

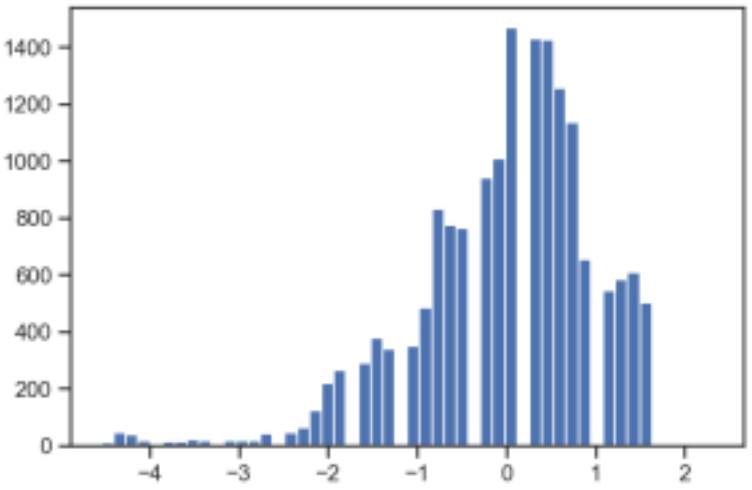
1400
1200
1000
800
600
400
200
0
−4
−3
−2
−1
0
1
2